

# Determinantes de las Expectativas de Inflación: Un Enfoque de Machine Learning

Javier Navarrete Twyman  
javier.navarrete@uc.cl

Pedro Skorin  
ppskorin@uc.cl

Kiran Sargent  
kiran.sargent@uc.cl

## ABSTRACT

*Los Bancos Centrales modernos utilizan cada vez más información de las expectativas de los agentes para la formulación de políticas monetarias. Conocer cómo los agentes forman sus expectativas y disponer de esta información para una mayor parte de la población es relevante para este tipo de institución, que invierte cada vez más en investigaciones con las empresas y la población. En este proyecto, usamos los modelos de Random Forest, XGBoost y Multi-layer Perceptron para predecir la expectativa de inflación a nivel individual con características demográficas y socioeconómicas de los agentes. Utilizando encuestas de expectativas de inflación del FED de Nueva York, encontramos que el modelo de Random Forest tiene el mejor rendimiento en las predicciones de las expectativas. Además, encontramos que variables socioeconómicas, como ingresos, ubicación y educación, ayudan más a explicar las expectativas que variables demográficas como género o grupo étnico.*

## 1. Introducción

En el ámbito de la macroeconomía y las políticas monetarias, las expectativas de inflación de los agentes económicos juegan un papel crucial. Los Bancos Centrales modernos utilizan cada vez más esta información para formular políticas monetarias efectivas (CHRISTELIS et al., 2020). Entender cómo se forman estas expectativas y disponer de esta información de manera precisa para una mayor parte de la población es fundamental para estas instituciones, las cuales invierten considerablemente en investigaciones con empresas y la ciudadanía. La formación de expectativas de inflación por parte de los individuos no solo refleja su percepción sobre la economía actual y futura, sino que también influye en sus decisiones de consumo y ahorro, afectando así la demanda agregada y, por ende, la inflación real (KOSE et al., 2019). Por lo tanto, los Bancos Centrales, como la Reserva Federal (FED) de Nueva York, llevan a cabo encuestas periódicas para recolectar datos sobre las expectativas de inflación de los consumidores (NYFED, 2024).

En este contexto, nuestro proyecto se centra en explorar y analizar estas expectativas de inflación utilizando técnicas de aprendizaje supervisado de machine learning<sup>1</sup>. La pregunta de investigación que guía este trabajo es: ¿Qué características son más importantes en la predicción de las expectativas de inflación? Para abordar esta pregunta, utilizamos datos provenientes de la encuesta de expectativas de inflación de la FED de Nueva York. Esta encuesta proporciona una amplia gama de información demográfica y socio-económica de los individuos, como edad, género, estado de empleo, ingresos, estado civil, estado de residencia, entre otros. Estas características se emplean como atributos en modelos de inteligencia artificial para predecir las expectativas de inflación.

La literatura ha empleado modelos de machine learning y expectativas de inflación en un mismo contexto anteriormente. El paper de Angelico et al. (2022) emplea métodos de machine-learning con datos de redes sociales para predecir el comportamiento de series temporales de expectativas de inflación. Por otro lado, Lin (2021) utiliza un modelo Markov Regime Transfer Vector Autoregressive (MSVAR) para estimar los efectos de comunicación del Banco Central de China en las expectativas de inflación. Con relación a la literatura, la novedad de este trabajo es usar variables de fácil acceso, como datos demográficos, para hacer estimaciones de las expectativas a nivel individual<sup>2</sup>. El análisis de estos datos mediante técnicas avanzadas de machine learning no solo permite mejorar la precisión de las predicciones, sino que también ayuda a identificar las variables más influyentes en la formación de expectativas. Esto, a su vez, proporciona a los Bancos Centrales herramientas más robustas para la formulación

<sup>1</sup>Para revisar el código del proyecto, se recomienda ver el repositorio online en [github](https://github.com).

<sup>2</sup>El trabajo también contribuye a la creciente discusión de agentes heterogéneos en modelos macroeconómicos, ofreciendo evidencia de cómo distintos atributos de los agentes impactan en la formación de las expectativas (XU et al., 2016).

de políticas monetarias, permitiendo una gestión más efectiva de la inflación y la estabilidad económica. En las siguientes secciones, se detallarán la metodología utilizada, los resultados obtenidos, y se discutirán las implicaciones de estos hallazgos, concluyendo con las posibles direcciones futuras para investigaciones adicionales en este ámbito.

## 2. Metodología

En este estudio, se utilizaron tres modelos de machine learning para predecir las expectativas de inflación basadas en características demográficas y socio-económicas. Los modelos seleccionados fueron: Multilayer Perceptron, Random Forest y XGBoost. Multilayer Perceptron es un modelo que captura de buena manera no linealidades y es flexible. El modelo Random Forest, un método de ensamble basado en múltiples árboles de decisión, fue elegido por su robustez y capacidad para manejar relaciones no lineales y datos heterogéneos. Por último, se utilizó XGBoost, un método avanzado de boosting, conocido por su eficiencia y precisión en tareas de predicción complejas.




Figura 1: Variables dependientes

Como variable dependiente, se usó la pregunta 8 del cuestionario hecho por la FED de Nueva York. La pregunta traducida al español es la siguiente *¿Cuál esperas que sea la tasa de inflación durante los próximos 12 meses?* (NYFED, 2024). Con eso se construye una variable continua que será usada como la expectativa de inflación del agente. La base de datos disponible contiene datos de varios meses, pero se concentrará solamente en predecir para el mes de agosto de 2013 (por concentrar el mayor numero de observaciones). La investigación se concentra en solamente un mes por dos motivos. Primero, de esa manera no se entra en la problemática de comparar agentes distintos en periodos distintos. Se descompone el componente del tiempo del análisis, mejorando la interpretación de los resultados a nivel de características de los individuos. Segundo, usar todos los datos disponibles resulta en un tiempo de computación muy grande en Google Colab, complicando el avance de la investigación. Con el filtro para el mes de agosto de 2013, la base de datos final termina con 1730 observaciones (todas sin missing values).

En la parte izquierda de la Figura 1, se puede observar la distribución de la variable dependiente de expectativa de inflación. La variable tiene una concentración al rededor de su mediana (igual a 4 %) con colas a la derecha y a la izquierda de la distribución. Como se entiende que valores lejanos a la mediana pueden significar sentimientos reales de los agentes, no lo interpretamos como outliers y dejamos la información para que los algoritmos absorban su varianza. Para que no se pondere de manera exagerada las observaciones muy lejanas, se escoge el MAE (Mean Absolute Error) como métrica para la regresión. Además, en algunos casos es posible que la pregunta de interés no sea saber exactamente la expectativa del agente, pero si su expectativa relativa a toda la economía. Con ese objetivo se crea una variable categórica llamada tipo de expectativa. El tipo se divide en inflación baja<sup>3</sup>, menor que 4 %, e inflación alta, mayor o igual que 4 %. En la parte de la derecha de la Figura 1 se puede notar que la variable es relativamente balanceada, con 46 % de las observaciones siendo del grupo de inflación baja y 53 % del grupo de inflación alta. En este proyecto, haremos dos estimaciones: una regresión de la expectativa de inflación y una clasificación entre expectativa alta o baja.

<sup>3</sup>Codificamos el grupo de inflación baja como cero y el grupo de inflación alta como 1.

Cuadro 1: Features del modelo

Feature	Tipo	Numero de categorías
Edad	Numérico	-
Estado de EUA	Categorico	52
Ingreso	Categorico	11
Situación Laboral	Categorico	10
Genero	Categorico	2
Grupo Étnico	Categorico	6
Situación Matrimonial	Categorico	2
Educación	Categorico	9
Te consideras latino?	Categorico	2

En el Cuadro 1, se presentan las nueve features del modelo y sus tipos. La única feature numérica es la edad de los agentes. Se nota que la base de datos contiene desde características económicas, como nivel de ingreso, situación laboral y estado de residencia, hasta variables demográficas, como genero, grupo étnico y la dummy de latino. Estas diferencias serán compradas en el análisis de feature relevance<sup>4</sup>. Para optimizar los modelos, se implementó una búsqueda de hiperparámetros mediante GridSearchCV. En el Cuadro 2 se presenta la información de los valores asociados a cada modelo. Para no sesgar la metodología para algún modelo, se escogieron los cinco hiperparámetros de los tres modelos más comunes de ajuste. El objetivo de esta búsqueda fue identificar la combinación de hiperparámetros que minimizara el MAE para la regresión y que maximiza el accuracy para la clasificación. La decisión por la accuracy viene de que los grupos son balanceados y no existe ningún beneficio a priori en maximizar la precisión o el recall.

Cuadro 2: Parámetros de Gridsearch

Modelo	Hyperparametro	Valores
Neural Network	hidden_layer_sizes	[(50,50,50), (50,100,50), (100,0)]
	activation	['identity', 'relu']
	solver	['sgd', 'adam']
	alpha	[0.0001, 0.05]
	learning_rate	['constant', 'adaptive']
Random Forest	n_estimators	[100, 200, 300]
	max_depth	[10, 20, 30, None]
	min_samples_split	[2, 5, 10]
	min_samples_leaf	[1, 2, 4]
	max_features	['sqrt', 'log2']
XGBoost	n_estimators	[100, 200, 300]
	learning_rate	[0.01, 0.1, 0.2]
	max_depth	[3, 6, 9]
	subsample	[0.6, 0.8, 1.0]
	colsample_bytree	[0.6, 0.8, 1.0]

El proceso de ingeniería de características incluyó dos transformaciones críticas para asegurar la eficacia de los modelos. Se utilizó `pd.get_dummies` para la codificación de variables categóricas, transformándolas en variables dummy. Esto permitió que los modelos de machine learning manejaran las variables categóricas de manera efectiva. Además, se aplicó `StandardScaler` para estandarizar y escalar las variables continuas, garantizando que todas las características tuvieran una escala comparable (importante para el modelo de Multilayer Perceptron). Como se tiene el objetivo de entender la importancia de las variables dentro de los algoritmos, se mantuvo la integridad de los datos durante el preprocesamiento, no se aplicó reducción de dimensionalidad. Finalmente, el procedimiento de entrenamiento y evaluación incluyó la división del conjunto de datos en un 80 % para entrenamiento y un 20 % para prueba, utilizando `train_test_split`.

<sup>4</sup>Para un análisis más profundo de las features, se recomiendo ver el Markdown del proyecto.

### 3. Resultados

Empezando por el problema de regresión, como comentado la principal métrica escogida fue el MAE. La métrica se considera mejor que el root mean square error por no ponderar tanto errores más grandes (ya que no transformamos la variable dependiente), pero igual se computa el RMSE por completitud. En el Cuadro 3, se presentan las métricas de MAE, RMSE, y también la métrica de tiempo de computación. Se puede observar que los modelos basados en árbol tiene métricas mejores en general que el modelo de redes neurales. Además, el tiempo de computo del XGBoost es considerablemente menor que en los otros modelos. Entre el modelo de Random Forest y XGBoost, el modelo de Random Forest es levemente mejor en las métricas de MAE y RMSE, a pesar de que el XGBoost es significativamente más rápido que el Random Forest. En general los errores son razonablemente grandes comparado con el promedio de la variable dependiente, pero hay que recordar dos factores. Primero, estamos estimando la expectativa de inflación a nivel individual, lo que aumenta bastante la varianza entre las observaciones. Segundo, hay un interés grande del proyecto en no solo escoger el mejor predictor, pero también entender como se construyó esa decisión. Para eso haremos un calculo de feature relevance en la siguiente sección.

Cuadro 3: Performance del problema de regresión

Model	MAE	RMSE	Tiempo (minutos)
Neural Network	7.72	14.50	6.6
Random Forest	7.31	14.20	7.9
XGBoost	7.34	14.38	3.9

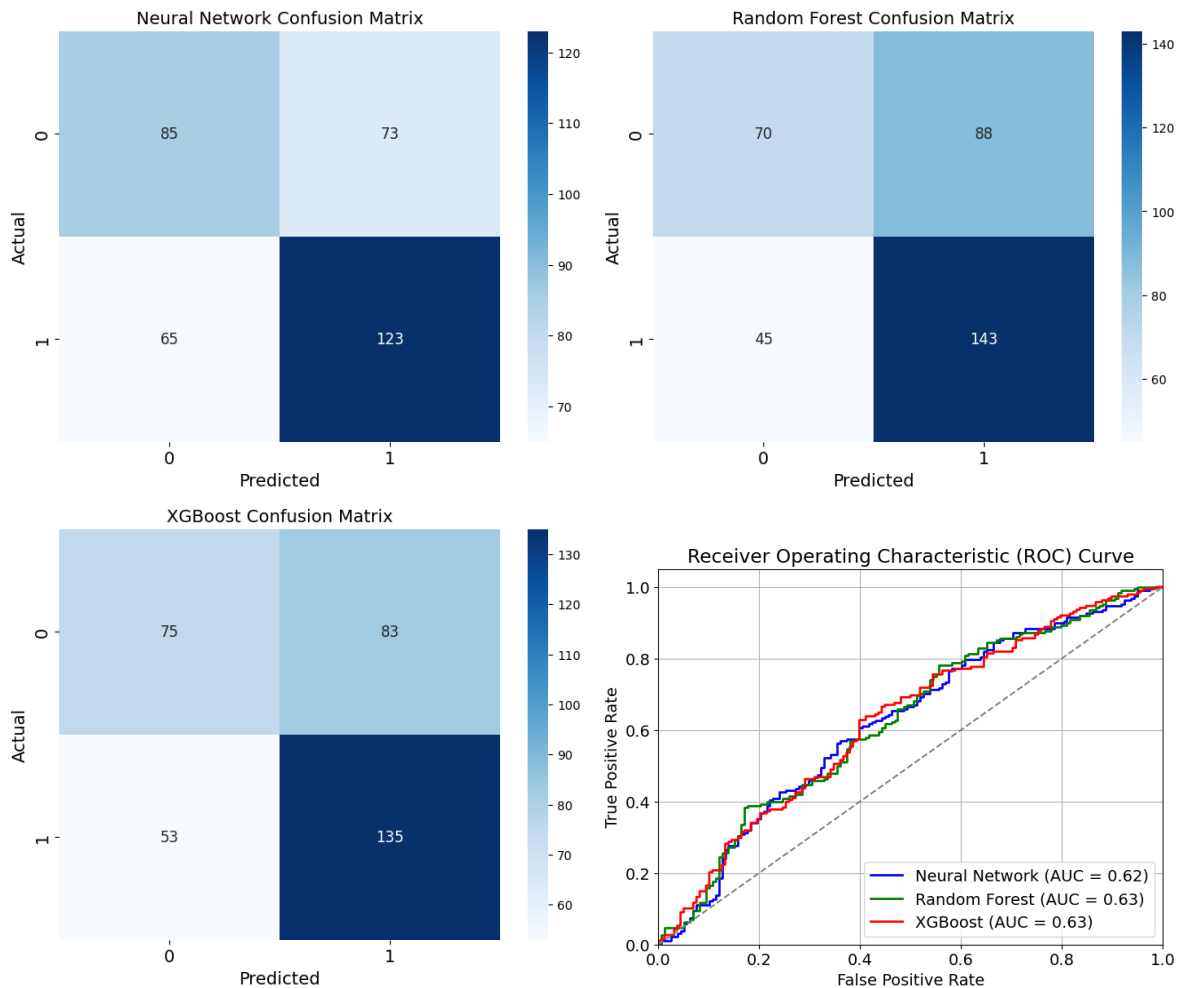


Figura 2: Evaluación de modelos de clasificación

Para el modelo de clasificación<sup>5</sup>, se computaron 5 métricas numéricas y dos gráficos. En el Cuadro 4, se observa que nuevamente los modelos basados en árboles superan al modelo de redes neurales en todas las métricas. Ya entre los modelos XGBoost y Random Forest, el segundo supera el primero por poco en las métricas de Accuracy y Recall, pero empata en las métricas de AUC y Precision. Con relación al tiempo de computo, el modelo XGBoost supera significativamente al Random Forest. Como comentado en la sección de metodología, no hay a priori ninguna inclinación por maximizar Precision o Recall en este proyecto (un Banco Central podría estar interesado en estimar bien tanto los agentes que esperan una deflación cuanto aquellos que esperan una alta inflación), por lo que nos centramos en generalizar el modelo y usar el Accuracy como métrica principal. Para la Curva ROC, no existe un ganador claro entre los modelos, lo que es visible también en el calculo del AUC.

Cuadro 4: Performance del problema de clasificación

Model	Accuracy	Precision	Recall	AUC	Tiempo (minutos)
Neural Network	0.601	0.628	0.654	0.62	8.0
Random Forest	0.616	0.619	0.761	0.63	9.2
XGBoost	0.607	0.619	0.718	0.63	3.6

## 4. Discusión

En esta sección se analizan dos factores: las potenciales causas de las diferencias en rendimiento y un estudio de relevancia de las features. Para lo primero, el importante es entender porque los modelos de redes neurales rindieron peor que los basados en árbol. Una posible justificación es que los modelos de redes neurales suelen necesitar de muchas observaciones para mejorar sus métricas. En este caso, estamos usando cerca de 1700 observaciones (aproximadamente 1300 para entrenar los algoritmos), lo que en general no se puede considerar como un gran numero de datos. Posiblemente con un mayor numero de observaciones, el modelo se ajustaría mejor para la predicción *out-of-sample*. Sin embargo, ya se notó en este ejercicio que el tiempo de computación del Multilayer Perceptron es mayor que algunos modelos basados en árbol. Es posible que con más observaciones, el algoritmo enfrente problemas de convergencia aún mayores.




Figura 3: Evaluación de importancia de las features en los modelos de Random Forest

Entre los modelos de árbol, la diferencia de las métricas es pequeña. El modelo de Random Forest suele ser más preciso, pero a un costo computacional mayor. Se sabe de la literatura que modelos XGBoost demandan mayor *hyperparameter tuning* para optimizar sus métricas y evitar el overfitting. Es posible que la grilla del cross-validation tenga que ser mayor para el modelo de XGBoost si se quiere obtener mejores métricas de rendimiento. Por el costo computacional, elegir el XGBoost en este contexto no sería una mala decisión, pero seguiremos con la elección del Random Forest dando más peso a las otras métricas.

En la Figura 3, se computa la importancia de cada variable en estimar la predicción para los modelos de Random Forest. Para eso, se utiliza el método `feature_importances` de `scikit-learn`. El método funciona calculando el promedio de la reducción de la impureza (por ejemplo, la impureza de Gini) en cada árbol del conjunto, asignada a cada

<sup>5</sup>Los parámetros seleccionados por Cross-Validation están en Markdown del proyecto.

característica a lo largo de todos los árboles, resultando en un puntuación de importancia para cada característica (HASTIE et al., 2009). Se puede concluir que las variables socio-económicas, como ingresos, educación y localización, suman importancias significativamente mayores que las variables demográficas como latino, grupo étnico y género. El resultado se relaciona con la creciente literatura sobre desigualdad en inflación Jaravel (2021). Se sabe que los agentes enfrentan inflaciones de manera distinta a depender de su nivel de ingresos en la sociedad. La percepción de la inflación puede ser mayor si el conjunto de bienes que sube de precio tiene una proporción mayor del ingreso del agente, por ejemplo. Además, la inflación puede ser sentida de manera distinta a nivel regional, explicando porque el estado de residencia es una variable tan relevante en las dos estimaciones. Dentro de ese contexto, los resultados encontrados aquí ayudan a aumentar la evidencia de que desigualdad de ingreso y heterogeneidades regionales están impactando la formación de las expectativas de los agentes.

## 5. Conclusión

En este proyecto, se estimó la expectativa de inflación de individuos usando dos variables dependientes: la propia expectativa de inflación y una variable categórica de inflación baja y alta. Los modelos que tuvieron las mejores métricas para ambos casos fueron los basados en árboles, siendo el Random Forest el modelo con mejores métricas con excepción del tiempo de computo, donde se destacó el XGBoost. La pregunta que centró el análisis fue entender cuales son las variables más relevantes para las estimaciones. Calculando la feature importance, se determinó que las variables socioeconómicas, como ingreso, educación y estado de residencia, fueron más importantes que variables demográficas, como género, grupo étnico y ser o no latino. El resultado contribuye con dos literaturas. Primero genera evidencias de que características de los individuos contribuyen para la formación de expectativas heterogéneas entre los agentes, como en Xu et al. (2016). Segundo, sustenta la literatura sobre desigualdad en la inflación, como en Jaravel (2021). La evidencia puede ayudar a los Bancos Centrales a hacer políticas de información a la población más focalizadas. Recientemente, ha existido un esfuerzo de los Bancos Centrales en mejorar la comunicación con la población con el objetivo de anclar sus expectativas. Si un Banco Central sabe cual segmento de la población sistemáticamente espera una inflación mayor, puede ser más eficiente en su comunicación, anclando las expectativas de forma menos costosa.

Como futuros avances, se recomiendan dos caminos. Primero, expandir el análisis hecho para más observaciones. Eso ayudaría a garantizar que los resultados pueden ser extrapolados a otros contextos, aumentando la evidencia de que las respuestas encontradas aquí son suficientemente generales para relevancia en más Bancos Centrales. Segundo, se recomienda entrar en los detalles de como las features pueden estar afectando en el outcome final. A pesar de menos interpretativos que otros modelos como árboles de decisión, aún es posible computar indicadores que traen una interpretación a los parámetros estimados en modelos de Random Forest. Métodos como el SHAP (SHapley Additive exPlanations) y el LIME (Local interpretable model-agnostic explanations) fueron creados con la intención de computar la relación entre las features y la variable dependiente. Por ejemplo, en este proyecto se obtiene la respuesta de que el ingreso es un factor relevante para la estimación de la expectativa de los agentes. Se plantea la pregunta de como esta variable está afectando la expectativa para futuros trabajos.

## Referencias

- ANGELICO, Cristina et al. Can we measure inflation expectations using Twitter? *Journal of Econometrics*, Elsevier, v. 228, n. 2, p. 259-277, 2022.
- CHRISTELIS, Dimitris et al. Trust in the central bank and inflation expectation. *Available at SSRN 3540974*, 2020.
- HASTIE, Trevor et al. *The elements of statistical learning: data mining, inference, and prediction*. Springer, 2009. v. 2.
- JARAVEL, Xavier. Inflation inequality: Measurement, causes, and policy implications. *Annual Review of Economics*, Annual Reviews, v. 13, n. 1, p. 599-629, 2021.
- KOSE, M Ayhan et al. Inflation expectations: review and evidence. CEPR Discussion Paper No. DP13601, 2019.
- LIN, Nan. Analysis of the impact of inflation expectations based on machine learning intelligent models. *Journal of Intelligent & Fuzzy Systems*, IOS Press, v. 40, n. 4, p. 6581-6592, 2021.
- NYFED. Consumers' Household Financial Expectations Rise; Inflation Expectations Lower at Short Term. *Survey of Consumer Expectations*, 2024. Disponible en: <https://www.newyorkfed.org/microeconomics/sce>. Acceso en: 26 jun. 2024.
- XU, Yingying et al. Modeling heterogeneous inflation expectations: empirical evidence from demographic data? *Economic Modelling*, Elsevier, v. 57, p. 153-163, 2016.